

Chapitre 2 — Processus ARMA

Économétrie Financière · M2

Bilel Sanhaji

Objectifs du chapitre

- Maîtriser le vocabulaire des séries temporelles (stationnarité, ergodicité, processus intégrés)
- Construire et caractériser (moments, ACF, PACF) les processus AR, MA et ARMA
- Estimer un ARMA, sélectionner son ordre, valider sa spécification
- Reconnaître les limites du modèle ARMA — la variance conditionnelle constante — qui motivent le chapitre 3

Introduction

Séries temporelles et processus stochastiques

Une **série temporelle** $\{y_t\}_{t=1}^T$ est la réalisation, de dimension finie, d'un **processus stochastique** $\{y_t(\omega), \omega \in \Omega, t \in \mathbb{T}\}$ — une suite ordonnée de variables aléatoires.

But de l'analyse : formuler un modèle statistique **congruent** avec le processus (inconnu) qui a généré la série observée. Approche **conditionnelle** — décomposition prévision-erreur :

$$y_t = \mathbb{E}[y_t \mid Y_{t-1}] + \varepsilon_t$$

où $\mathbb{E}[y_t \mid Y_{t-1}]$ est la partie prévisible, ε_t l'information imprévisible (l'innovation).

Stationnarité

$\{y_t\}$ est **stationnaire au sens faible** (ou d'ordre 2) si ses deux premiers moments existent et ne dépendent pas de t :

$$\mathbb{E}[y_t] = \mu < \infty, \quad \mathbb{E}[(y_t - \mu)(y_{t-h} - \mu)] = \gamma(h) \quad \forall t, h$$

$\{y_t\}$ est **strictement stationnaire** si la distribution jointe de $(y_t, y_{t+h_1}, \dots, y_{t+h_n})$ ne dépend que des écarts h_i , jamais de t .

Pour un processus **gaussien**, stationnarité faible $\Leftrightarrow$ stationnarité stricte. C'est l'hypothèse de travail par défaut de ce chapitre comme du chapitre 3.

Ergodicité

$\{y_t\}$ stationnaire est **ergodique pour la moyenne** si $\bar{y}_T = T^{-1} \sum_t y_t \xrightarrow{p} \mu$ quand $T \rightarrow \infty$.

Stationnarité et ergodicité sont **deux notions distinctes**. Exemple : $y_t = u_0$ pour tout $t \geq 0$, $u_0 \sim \mathcal{N}(0, \sigma^2)$ — ce processus est stationnaire ($\mu = 0$, $\gamma(h) = \sigma^2$ indépendants de t) mais **non ergodique** : $\bar{y}_T = u_0$ pour tout T , ne converge jamais vers 0.

Condition suffisante d'ergodicité pour un processus stationnaire : sommabilité absolue des autocovariances, $\sum_h |\gamma(h)| < \infty$. C'est l'ergodicité qui autorise, en pratique, à caractériser un processus par ses moments **empiriques** (moyenne, ACF, PACF).

Processus intégrés

Un processus est **intégré d'ordre d** , noté $I(d)$, s'il faut le différencier d fois pour le rendre stationnaire. Un processus stationnaire est $I(0)$.

Marche aléatoire : $y_t = y_{t-1} + u_t, u_t \sim \text{i.i.d.}(0, \sigma^2), y_0 = 0$ — c'est un $I(1)$ typique :

$$\mathbb{E}(y_t) = 0, \quad \mathbb{V}(y_t) = t\sigma^2 \text{ (diverge avec } t), \quad \rho_t(h)^2 = 1 - \frac{h}{t}$$

Signature empirique : l'ACF d'une série $I(1)$ décroît très lentement (quasi linéairement), alors que celle d'une série stationnaire oscille autour de 0. La PACF d'une $I(1)$ a un premier coefficient proche de 1, puis chute — signature utile pour repérer visuellement une non-stationnarité avant tout test formel.

Bruit blanc et IID

$\{u_t\}$ est un **bruit blanc**, $u_t \sim \text{WN}(0, \sigma^2)$, si $\mathbb{E}(u_t) = 0$, $\mathbb{V}(u_t) = \sigma^2 < \infty$, et u_t, u_{t-h} non corrélés pour $h \neq 0$. S'il est de plus gaussien : $u_t \sim \text{NID}(0, \sigma^2)$ — non-corrélation $\Leftrightarrow$ indépendance.

Généralisation : $u_t \sim \text{IID}(\mu, \sigma^2)$ — composantes indépendantes et identiquement distribuées, moments d'ordre supérieur non précisés.

Un bruit blanc est-il nécessairement i.i.d. ? (Non — seule la non-corrélation est requise ; l'indépendance complète, plus forte, n'est garantie que sous normalité ou avec l'hypothèse IID explicite.)

Filtre linéaire et décomposition de Wold

Filtre linéaire : $y_t = A(L)x_t = \sum_j a_j x_{t-j}$.

Décomposition de Wold : tout processus stationnaire de covariance, à moyenne nulle, se représente

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t, \quad \psi_0 = 1, \quad \sum_j \psi_j^2 < \infty$$

avec $\varepsilon_t \equiv y_t - \widehat{\mathbb{E}}(y_t \mid Y_{t-1})$ l'erreur de prévision linéaire, et κ_t une composante déterministe (parfaitement prévisible).

Approche de Box-Jenkins : approximer $\Psi(L) = \sum_j \psi_j L^j$ par un rapport de deux polynômes de degré fini :

$$\Psi(L) \simeq \frac{\beta(L)}{\alpha(L)} = \frac{1 + \beta_1 L + \dots + \beta_q L^q}{1 - \alpha_1 L - \dots - \alpha_p L^p}$$

Type	Modèle	p	q
AR(p)	$\alpha(L)y_t = \varepsilon_t$	> 0	0
MA(q)	$y_t = \beta(L)\varepsilon_t$	0	> 0

Processus autorégressifs

AR(1) : définition et moments

$$y_t = \nu + \varphi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

Si $|\varphi| < 1$ (stationnarité), représentation $\text{MA}(\infty)$ par substitution récursive :

$$y_t = \frac{\nu}{1 - \varphi} + \sum_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}$$

$$\mathbb{E}(y_t) = \frac{\nu}{1 - \varphi} = \mu, \quad \mathbb{V}(y_t) = \gamma(0) = \frac{\sigma^2}{1 - \varphi^2}$$

Autocovariance, autocorrélation

$$\gamma(h) = \varphi \gamma(h - 1) = \varphi^h \gamma(0), \quad \rho(h) = \varphi^h, \quad h \neq 0$$

$\varphi = \text{Corr}(y_t, y_{t-1})$: c'est directement le coefficient de corrélation entre deux dates consécutives.

Caractérisation ACF/PACF d'un AR(1) :

- ACF : décroissance **exponentielle** si $\varphi > 0$, **sinusoïde amortie** si $\varphi < 0$.
- PACF : un seul coefficient non nul (au retard 1, de signe celui de φ), puis nulle.

Cas limites

- $\varphi = 0$: bruit blanc, imprévisible.
- $|\varphi| < 1$: stable, oscille autour de μ — cas stationnaire.
- $|\varphi| = 1$: marche aléatoire, **non stationnaire** ($I(1)$).
- $|\varphi| > 1$: **explosif**.

Un φ estimé très proche de 1 (par exemple $\hat{\varphi} = 0,97$) ne prouve pas la stationnarité : c'est le signe d'une **forte persistance**, à confirmer ou infirmer par un test formel de racine unitaire (ADF, KPSS) — voir TP2.

AR(2) : stationnarité

$$y_t = \nu + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \varepsilon_t$$

Conditions de stationnarité (triangle de stationnarité) :

$$\varphi_1 + \varphi_2 < 1, \quad \varphi_2 - \varphi_1 < 1, \quad |\varphi_2| < 1$$

Racines complexes (comportement pseudo-cyclique) si $\varphi_1^2 + 4\varphi_2 < 0$.

Équations de Yule-Walker :

$$\rho(1) = \varphi_1 + \varphi_2 \rho(1), \quad \rho(2) = \varphi_1 \rho(1) + \varphi_2$$

AR(p) et équations de Yule-Walker générales

$$y_t = \nu + \sum_{j=1}^p \varphi_j y_{t-j} + \varepsilon_t$$

Stabilité : les racines de $\alpha(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p = 0$ sont toutes $|z| > 1 \Rightarrow$ stationnarité, représentation MA(∞) avec $\sum_j |\psi_j| < \infty$.

Système de Yule-Walker (pour $\rho(1), \dots, \rho(p)$, puis récursion pour $k > p$) :

$$\rho(k) = \varphi_1 \rho(k-1) + \dots + \varphi_p \rho(k-p)$$

Signature ACF/PACF d'un AR(p) : ACF décroît de façon exponentielle (ou sinusoidale amortie), PACF nulle après le retard p — c'est ce second critère qui identifie l'ordre p en pratique.

Processus de moyenne mobile

MA(q) : définition et moments

$$y_t = \mu + \varepsilon_t + \sum_{i=1}^q \beta_i \varepsilon_{t-i}, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

Toujours stationnaire, quels que soient les β_i .

$$\gamma(0) = \left(1 + \sum_{i=1}^q \beta_i^2\right) \sigma^2, \quad \gamma(k) = \sigma^2 \sum_{j=0}^{q-k} \beta_j \beta_{j+k} \quad (1 \leq k \leq q), \quad \gamma(k) = 0 \quad (k > q)$$

Signature ACF/PACF d'un MA(q) : ACF **s'annule après le retard q** (coupure nette), PACF décroît exponentiellement (ou sinusoïde amortie) — c'est l'exact miroir du couple AR/MA en termes d'ACF et de PACF.

Inversibilité

Les racines de $\beta(z) = 1 + \beta_1 z + \cdots + \beta_q z^q = 0$ toutes $|z| > 1 \Rightarrow$ **inversibilité** : représentation AR(∞)

$$y_t = \mu + \sum_{j=1}^{\infty} \phi_j (y_{t-j} - \mu) + \varepsilon_t$$

Un MA(1), $y_t = \varepsilon_t + \beta \varepsilon_{t-1}$, a la même fonction d'autocorrélation pour β et $1/\beta$: sans la condition d'inversibilité ($|\beta| < 1$), le modèle n'est pas identifié de façon unique à partir des seconds moments.

Processus ARMA(p, q)

Définition et conditions

$$\alpha(L)y_t = \nu + \beta(L)\varepsilon_t, \quad \alpha(L) = 1 - \varphi_1 L - \cdots - \varphi_p L^p, \quad \beta(L) = 1 + \beta_1 L + \cdots + \beta_q L^q$$

Trois conditions pour une représentation ARMA(p, q) **minimale** et bien définie :

1. **Stabilité** : racines de $\alpha(z)$ toutes $|z| > 1 \rightarrow$ forme MA(∞).
2. **Inversibilité** : racines de $\beta(z)$ toutes $|z| > 1 \rightarrow$ forme AR(∞).
3. **Pas de racine commune** entre $\alpha(L)$ et $\beta(L)$.

Une racine commune à $\alpha(L)$ et $\beta(L)$ produit une **sur-paramétrisation** : les deux facteurs se simplifient et le modèle « vrai » est d'ordre inférieur — piège classique de l'estimation automatique ([auto.arima](#)) sur un ordre mal choisi.

ARMA(1,1) : exemple complet

$$y_t - \varphi y_{t-1} = \varepsilon_t + \beta \varepsilon_{t-1}, \quad |\varphi| < 1, |\beta| < 1$$
$$\rho(1) = \frac{(1 + \varphi\beta)(\varphi + \beta)}{1 + \beta^2 + 2\varphi\beta}, \quad \rho(h) = \varphi^{h-1} \rho(1) \quad (h \geq 2)$$

Signature ACF/PACF d'un ARMA(p, q) : ni coupure nette ni décroissance à partir du premier retard sur l'un ou l'autre — les **deux** décroissent de façon exponentielle (ou sinusoidale amortie), sans annulation brutale. C'est ce profil mixte qui, en pratique, signale la nécessité d'un ARMA plutôt qu'un AR ou un MA pur.

Extension multivariée : VAR(1) (*Paris 8*)

Ce qui est vrai dans le cadre univarié se généralise au cadre multivarié : y_t devient un vecteur $\mathbf{y}_t$, les paramètres des matrices.

VAR(1) :

$$\mathbf{y}_t = \mathbf{A} \mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t, \quad \boldsymbol{\varepsilon}_t \sim \text{WN}(\mathbf{0}, \boldsymbol{\Sigma})$$

ADL (Autoregressive Distributed Lags) — cas particulier utile pour la causalité :

$$y_{1,t} = \alpha_{11}y_{1,t-1} + \alpha_{12}y_{2,t-1} + \varepsilon_{1t}$$

Si $\alpha_{12} \neq 0$, $y_{2,t-1}$ « cause » (au sens de Granger) $y_{1,t}$.

Estimation

Vraisemblance conditionnelle (cas AR(1))

Sous normalité conditionnelle, $(y_t \mid y_{t-1}) \sim \mathcal{N}(\nu + \varphi y_{t-1}, \sigma^2)$:

$$L(y_1, \dots, y_T \mid y_0; \nu, \varphi, \sigma^2) = (2\pi\sigma^2)^{-T/2} \exp \left(-\frac{1}{2\sigma^2} \sum_{t=1}^T (y_t - \nu - \varphi y_{t-1})^2 \right)$$

Le maximum de vraisemblance conditionnelle de (ν, φ) équivaut à minimiser la somme des carrés des résidus — **MLE** $\equiv$ **MCO** pour un AR(1) (et plus généralement pour un AR(p)). Sous stationnarité, $\sqrt{T}(\hat{\delta} - \delta) \overset{\text{asy}}{\sim} \mathcal{N}(0, \cdot)$.

Pour un MA ou un ARMA général, la vraisemblance **exacte** (incluant la condition initiale) diffère de la vraisemblance conditionnelle, mais les deux MLE sont asymptotiquement équivalentes.

Sélection de modèle : AIC, BIC

$$\text{AIC} = -2 \log L + 2p, \quad \text{BIC} = -2 \log L + \log(n) p$$

avec n le nombre d'observations, p le nombre de paramètres. **Plus petit est mieux.**

Le BIC pénalise davantage la complexité que l'AIC dès que $n > 7$ (car $\log n > 2$) : il tend à retenir des modèles plus **parcimonieux**. Sur un échantillon financier journalier (n dans les centaines ou milliers), les deux critères peuvent donc désigner des ordres différents — comparez toujours les deux.

Tests de mauvaise spécification

Pour un AR(1), $y_t = \nu + \varphi y_{t-1} + \varepsilon_t$, les hypothèses à valider : indépendance des ε_t , normalité conditionnelle, homoscedasticité.

Normalité : test de Jarque-Bera

$$JB = \frac{T - k}{6} \left(\hat{\kappa}_3^2 + \frac{\hat{\kappa}_4^2}{4} \right) \stackrel{H_0}{\sim} \chi^2(2)$$

$H_0 : \kappa_3 = \kappa_4 = 0$ (asymétrie et excès de kurtosis nuls), k = nombre de régresseurs.

Hétéroscédasticité : test de White (1980)

$H_0 : \mathbb{V}(\varepsilon_t \mid Y_{t-1})$ ne dépend pas de Y_{t-1} .

1. Résidus $\hat{\varepsilon}_t$ du modèle original.

2. Régression auxiliaire : $\hat{\varepsilon}_t^2 = \beta_1 + \beta_2 y_{t-1} + \beta_3 y_{t-1}^2 + \eta_t \rightarrow R_{het}^2$

3. $TR_{het}^2 \stackrel{H_0}{\sim} \chi_2^2$

Forme fonctionnelle : test RESET de Ramsey (1969)

H_0 : la forme fonctionnelle est correctement spécifiée (les polynômes de $\hat{y}_t$ n'apportent rien).

1. Valeurs ajustées $\hat{y}_t$ du modèle original.
2. Régression auxiliaire : $y_t = \beta_1 + \beta_2 y_{t-1} + \beta_3 \hat{y}_t^2 + \eta_t \rightarrow R_{reset}^2$
3. $TR_{reset}^2 \stackrel{H_0}{\sim} \chi_m^2$ (m = nombre de restrictions)

Autocorrélation résiduelle : Box-Pierce et Ljung-Box

$H_0 : \rho(1) = \dots = \rho(m) = 0$ sur les résidus.

$$Q(m) = T(T + 2) \sum_{h=1}^m \frac{\hat{\rho}(h)^2}{T - h} \stackrel{H_0}{\sim} \chi^2(m - p - q)$$

Application directe (déjà vue en TD1/TP1 sur les rendements bruts) : ici le test porte sur les résidus **d'estimation** d'un ARMA, pas sur la série brute — validation nécessaire avant d'utiliser le modèle pour prévoir.

Effet ARCH résiduel : test d'Engle (1982)

$H_0 : \mathbb{V}(\varepsilon_t \mid \varepsilon_{t-1}) \text{ constante.}$

1. Résidus $\hat{\varepsilon}_t$ de l'ARMA.

2. Régression auxiliaire : $\hat{\varepsilon}_t^2 = \beta_1 + \beta_2 \hat{\varepsilon}_{t-1}^2 + \eta_t \rightarrow R_{arch}^2$

3. $TR_{arch}^2 \stackrel{H_0}{\sim} \chi_m^2$

Application : persistance et mauvaise spécification

Exemple (taux de chômage américain, AR(1)) :

$$x_t = 5,59 + 0,97 x_{t-1} + \varepsilon_t \quad (\text{p-valeurs} \approx 0)$$

- Forte persistance ($\hat{\varphi} = 0,97$), mais pas de rejet formel de la stationnarité (ADF).
- Le test de normalité des résidus est **rejeté** : le modèle n'est pas congruent.

Une estimation « significative » (p-valeurs proches de 0) ne garantit pas un modèle correctement spécifié : les tests de diagnostic (normalité, hétéroscédasticité, autocorrélation résiduelle) doivent systématiquement être menés après l'estimation, jamais seulement la significativité des coefficients.

Références

- Box, G.E.P., Jenkins, G.M. (1976). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Engle, R.F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987-1007.
- Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- Ramsey, J.B. (1969). Tests for Specification Errors in Classical Linear Least-Squares Regression Analysis. *Journal of the Royal Statistical Society B*, 31(2), 350-371.
- White, H. (1980). A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity. *Econometrica*, 48(4), 817-838.