

Chapitre 4 — GARCH multivarié

Économétrie Financière · M2

Bilel Sanhaji

Objectifs du chapitre

- Comprendre pourquoi la modélisation univariée (chapitre 3) ne suffit pas dès qu'on détient plusieurs actifs
- Distinguer les deux grandes familles de modèles GARCH multivariés (VEC/BEKK vs. CCC/DCC)
- Maîtriser le modèle DCC — le plus utilisé en pratique — et son estimation en deux étapes
- Situer les limites pratiques de ces modèles (fléau de la dimension)

Introduction

Rendements et volatilité en univers multivarié

Soit p_{it} le prix de l'actif i à la date t , et son rendement $y_{it} = \log p_{it} - \log p_{i,t-1}$. En notation vectorielle, pour N actifs :

$$\mathbf{p}_t = (p_{1t}, \dots, p_{Nt})', \quad \mathbf{y}_t = \Delta \log \mathbf{p}_t$$

La **volatilité** d'un actif est l'écart-type (ou la variance) de son rendement ; la **covolatilité** entre deux actifs est la covariance entre leurs rendements. Comme la volatilité univariée, la volatilité multivariée est **latente** : jamais observée directement, seulement inférée à partir des rendements observés.

Pourquoi un modèle multivarié ?

Modéliser chaque série séparément (chapitre 3, actif par actif) laisse de côté l'information sur les **comouvements** entre actifs.

Motivations pratiques : allocation de portefeuille, VaR en portefeuille (pas seulement actif par actif), couverture (*hedging*) par contrats à terme, transmission de volatilité entre marchés, modèles d'évaluation d'actifs (CAPM conditionnel, etc.). Toutes ces applications ont besoin non seulement des variances individuelles h_{iit} , mais aussi des **covariances conditionnelles** h_{ijt} .

Le cadre général

$$\mathbf{y}_t = \boldsymbol{\mu}_t + \boldsymbol{\varepsilon}_t, \quad t = 1, \dots, T$$

avec $\boldsymbol{\mu}_t = \mathbb{E}(\mathbf{y}_t \mid \mathcal{F}_{t-1})$ (souvent $\mathbf{0}$, ou un VARMA — chapitre 2), et $\boldsymbol{\varepsilon}_t$ un vecteur $N \times 1$ tel que

$$\mathbb{E}(\boldsymbol{\varepsilon}_t \mid \mathcal{F}_{t-1}) = \mathbf{0}, \quad \mathbb{E}(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}_t' \mid \mathcal{F}_{t-1}) = \mathbf{H}_t$$

$\mathbf{H}_t = \mathbf{H}_t(\theta)$ est la **matrice de variance-covariance conditionnelle**. Un processus **GARCH multivarié** s'écrit

$$\boldsymbol{\varepsilon}_t = \mathbf{H}_t^{1/2} \mathbf{z}_t, \quad \mathbf{z}_t \sim \text{i.i.d.}(\mathbf{0}, \mathbf{I}_N)$$

$\mathbf{H}_t^{1/2}$ est n'importe quelle matrice $N \times N$ telle que $\mathbf{H}_t$ soit bien la variance conditionnelle de $\mathbf{y}_t$ (par exemple une factorisation de Cholesky).

Trois défis

1. **Positivité** : garantir $\mathbf{H}_t$ définie positive à toute date, sachant $\mathbf{H}_0$ définie positive.
2. **Parcimonie** : éviter l'explosion du nombre de paramètres tout en gardant une dynamique suffisamment riche pour $\mathbf{H}_t$.
3. **Stationnarité** : trouver la variance non conditionnelle $\mathbf{H} = \mathbb{E}(\mathbf{H}_t)$ et les conditions de son existence.

Par simplicité, on se limite ici aux modèles MGARCH(1,1) : $\mathbf{H}_t$ fonction d'un seul retard de $\boldsymbol{\varepsilon}_t$ et d'un seul retard de lui-même.

Typologie des modèles MGARCH

Généralisation multivariée du GARCH(1,1) univarié $h_t = \omega + \alpha \varepsilon_{t-1}^2 + \gamma h_{t-1}$:

- **Modèles de variances et covariances** : VEC, BEKK — généralisation directe, matricielle, de l'équation GARCH.
- **Modèles de variances et corrélations** : CCC, DCC — on sépare les variances individuelles (GARCH univariés) de la structure de corrélation entre elles.

Modèles de variances et covariances

VEC(1,1), cas bivarié

Bollerslev, Engle et Wooldridge (1988) :

$$h_{11t} = c_1 + a_{11}\varepsilon_{1,t-1}^2 + a_{12}\varepsilon_{1,t-1}\varepsilon_{2,t-1} + a_{13}\varepsilon_{2,t-1}^2 + g_{11}h_{11,t-1} + g_{12}h_{21,t-1} + g_{13}h_{22,t-1}$$

$$h_{21t} = c_2 + a_{21}\varepsilon_{1,t-1}^2 + a_{22}\varepsilon_{1,t-1}\varepsilon_{2,t-1} + a_{23}\varepsilon_{2,t-1}^2 + g_{21}h_{11,t-1} + g_{22}h_{21,t-1} + g_{23}h_{22,t-1}$$

$$h_{22t} = c_3 + a_{31}\varepsilon_{1,t-1}^2 + a_{32}\varepsilon_{1,t-1}\varepsilon_{2,t-1} + a_{33}\varepsilon_{2,t-1}^2 + g_{31}h_{11,t-1} + g_{32}h_{21,t-1} + g_{33}h_{22,t-1}$$

Nombre de paramètres en $O(N^4)$: 21 pour $N = 2$, 78 pour $N = 3$, 210 pour $N = 4$ — c'est le problème central de ce modèle, non paramétrique au sens économique du terme mais très vite ingérable numériquement.

Opérateurs vech et vec

vech empile le **triangle inférieur** d'une matrice symétrique $N \times N$ en un vecteur $N(N + 1)/2 \times 1$:

$$\text{vech } \mathbf{H}_t = (h_{11t}, h_{21t}, h_{22t}, h_{31t}, \dots, h_{NNt})'$$

vec empile **toute la matrice**, colonne par colonne.

VEC(1,1) général :

$$\text{vech } \mathbf{H}_t = \mathbf{c} + \mathbf{A} \text{vech}(\boldsymbol{\varepsilon}_{t-1} \boldsymbol{\varepsilon}_{t-1}') + \mathbf{G} \text{vech } \mathbf{H}_{t-1}$$

avec $\mathbf{c}$ un vecteur $N^* \times 1$, $\mathbf{A}$, $\mathbf{G}$ des matrices $N^* \times N^*$, $N^* = N(N + 1)/2$.

Stationnarité et positivité du VEC

Le VEC(1,1) se réécrit comme un VARMA(1,1) sur $\text{vech}(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}_t')$. Il est **faiblement stationnaire** si les valeurs propres de $\mathbf{A} + \mathbf{G}$ sont toutes < 1 en module ; alors

$$\text{vech } \mathbf{H} = (\mathbf{I}_{N^*} - \mathbf{A} - \mathbf{G})^{-1} \mathbf{c}$$

Positivité (Gouriéroux, 1997) : condition suffisante — $\mathbf{C}$, $\tilde{\mathbf{A}}$, $\tilde{\mathbf{G}}$ semi-définies positives, l'une au moins définie positive. En pratique ces contraintes ne sont **généralement pas imposées** lors de l'estimation, mais vérifiées après coup.

VEC diagonal et scalaire

DVEC (diagonal VEC) : $\mathbf{A}$ et $\mathbf{G}$ diagonales — chaque variance h_{iit} ne dépend que de son propre passé ($\varepsilon_{i,t-1}^2$, $h_{ii,t-1}$), chaque covariance h_{ijt} que du sien ($\varepsilon_{i,t-1}\varepsilon_{j,t-1}$, $h_{ij,t-1}$) — aucun effet de contagion (*spillover*).

Réduction drastique : 9 paramètres au lieu de 21 pour $N = 2$; 18 au lieu de 78 pour $N = 3$. **VEC scalaire** : $\mathbf{A} = a \mathbf{U}_N^*$, $\mathbf{G} = g \mathbf{U}_N^*$ ($\mathbf{U}_N^*$ matrice de uns) — seulement 2 paramètres dynamiques, quel que soit N .

BEKK(1,1,1), cas bivarié

Engle et Kroner (1995) — même structure que le VEC mais **paramétrée par construction pour garantir la positivité** :

$$\mathbf{H}_t = \mathbf{\Omega} + \mathbf{A}'\boldsymbol{\varepsilon}_{t-1}\boldsymbol{\varepsilon}_{t-1}'\mathbf{A} + \mathbf{G}'\mathbf{H}_{t-1}\mathbf{G}$$

$\mathbf{H}_t$ est définie positive dès que $\mathbf{H}_0$ et $\mathbf{\Omega}$ le sont — on peut imposer $\mathbf{\Omega} = \mathbf{C}'\mathbf{C}$ ($\mathbf{C}$ triangulaire) pour le garantir automatiquement. C'est l'avantage majeur du BEKK sur le VEC général : la positivité est **structurelle**, pas une contrainte à vérifier après coup.

11 paramètres pour $N = 2$ (contre 21 pour le VEC) — même souplesse, moins de paramètres, au prix d'une interprétation moins directe des coefficients individuels.

BEKK général et stationnarité

BEKK(1, 1, K) :

$$\mathbf{H}_t = \mathbf{\Omega} + \sum_{k=1}^K \mathbf{A}'_k \boldsymbol{\varepsilon}_{t-1} \boldsymbol{\varepsilon}'_{t-1} \mathbf{A}_k + \sum_{k=1}^K \mathbf{G}'_k \mathbf{H}_{t-1} \mathbf{G}_k$$

En réécriture $\text{vec}(\mathbf{ABC}) = (\mathbf{C}' \otimes \mathbf{A})\text{vec } \mathbf{B}$, le BEKK(1,1,1) est stationnaire si les valeurs propres de $(\mathbf{A} \otimes \mathbf{A}) + (\mathbf{G} \otimes \mathbf{G})$ sont < 1 en module.

BEKK scalaire diagonal ($\mathbf{A}_1 = a\mathbf{I}_N$, $\mathbf{G}_1 = g\mathbf{I}_N$) :

$$\mathbf{H}_t = \mathbf{\Omega} + \alpha \boldsymbol{\varepsilon}_{t-1} \boldsymbol{\varepsilon}'_{t-1} + \gamma \mathbf{H}_{t-1}, \quad \alpha + \gamma < 1$$

— exactement la forme d'un GARCH(1,1) univarié appliqué matriciellement.

Modèles de variances et corrélations

Décomposition variance-corrélation

Toute matrice $\mathbf{H}_t$ définie positive s'écrit

$$\mathbf{H}_t = \mathbf{D}_t \mathbf{R}_t \mathbf{D}_t, \quad \mathbf{D}_t = \text{diag}(h_{11t}^{1/2}, \dots, h_{NNt}^{1/2}), \quad \mathbf{R}_t = (\rho_{ijt}), \quad \rho_{iit} = 1$$

d'où $h_{ijt} = \rho_{ijt} \sqrt{h_{iit} h_{jjt}}$ pour $i \neq j$.

Chaque h_{iit} peut être une équation GARCH **univariée** classique (chapitre 3, estimée indépendamment) ; $\mathbf{H}_t$ est définie positive dès que $\mathbf{R}_t$ et tous les h_{iit} le sont — bien plus facile à garantir qu'en VEC/BEKK.

CCC — Corrélations Conditionnelles Constantes

Bollerslev (1990) :

$$\mathbf{R}_t = \mathbf{R} = (\rho_{ij}), \quad \rho_{ii} = 1 \quad (\text{constante dans le temps})$$

La dynamique des **covariances** provient uniquement de celle des **variances** individuelles ($h_{ijt} = \rho_{ij} \sqrt{h_{iit} h_{jjt}}$) — $N(N - 1)/2$ paramètres seulement dans $\mathbf{R}$. Hypothèse forte : aucune évolution des corrélations dans le temps.

DCC — Corrélations Conditionnelles Dynamiques

Engle (2002), version scalaire :

$$\mathbf{R}_t = (\text{Diag } \mathbf{Q}_t)^{-1/2} \mathbf{Q}_t (\text{Diag } \mathbf{Q}_t)^{-1/2}$$

$$\mathbf{Q}_t = (1 - \theta_1 - \theta_2) \overline{\mathbf{Q}} + \theta_1 \mathbf{u}_{t-1} \mathbf{u}_{t-1}' + \theta_2 \mathbf{Q}_{t-1}$$

avec $u_{it} = \varepsilon_{it} / \sqrt{h_{iit}}$, $\overline{\mathbf{Q}}$ symétrique définie positive, $\theta_1, \theta_2 > 0, \theta_1 + \theta_2 < 1 \Rightarrow \mathbf{Q}_t, \mathbf{R}_t$ définies positives.

$\mathbf{Q}_t$ **n'est pas** elle-même une matrice de corrélation (ses termes diagonaux ne valent pas 1) — c'est la normalisation par $(\text{Diag } \mathbf{Q}_t)^{-1/2}$ qui produit $\mathbf{R}_t$, une vraie matrice de corrélation.

Si $\theta_1 = \theta_2 = 0$ (et $\overline{q}_{ii} = 1$), on retrouve exactement le CCC : **le CCC est un cas particulier testable du DCC.**

DCC asymétrique (ADCC)

$$\mathbf{Q}_t = \mathbf{\Omega} + \theta_1 \mathbf{u}_{t-1} \mathbf{u}_{t-1}' + \gamma \eta_{t-1} \eta_{t-1}' + \theta_2 \mathbf{Q}_{t-1}, \quad \eta_t = \min(\mathbf{u}_t, \mathbf{0})$$

Si $\gamma > 0$: les corrélations augmentent **davantage** quand les deux chocs sont négatifs (marché en baisse) que lorsqu'ils sont positifs — l'analogue, pour les corrélations, de l'effet de levier vu au chapitre 3 pour la volatilité (GJR-GARCH, EGARCH).

Toutes les corrélations obéissent à la **même** dynamique (θ_1, θ_2 scalaires) — économe en paramètres, mais restrictif quand N est grand.

Nombre de paramètres : CCC/DCC vs VEC/BEKK

	$N = 2$	$N = 3$	$N = 4$	$N = 5$
VEC(1,1)	21	78	210	465
BEKK(1,1,1)	11	24	42	65
CCC	7	12	18	25
DCC	9	14	20	27

Estimation

Maximum de vraisemblance

Sous une densité $g(\mathbf{z}_t; \eta)$ pour $\mathbf{z}_t$:

$$L_T(\theta, \eta) = \sum_{t=1}^T \log f(\mathbf{y}_t \mid \theta, \eta, \mathcal{I}_{t-1}), \quad f(\mathbf{y}_t \mid \cdot) = |\mathbf{H}_t|^{-1/2} g(\mathbf{H}_t^{-1/2}(\mathbf{y}_t - \boldsymbol{\mu}_t); \eta)$$

Vraisemblance gaussienne ($\mathbf{z}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$) :

$$L_T(\theta) = -\frac{1}{2} \sum_{t=1}^T \left(\log |\mathbf{H}_t| + (\mathbf{y}_t - \boldsymbol{\mu}_t)' \mathbf{H}_t^{-1} (\mathbf{y}_t - \boldsymbol{\mu}_t) \right)$$

Cette **quasi-vraisemblance gaussienne (QMLE)** reste consistante même si la vraie densité n'est pas gaussienne (pourvu que $\boldsymbol{\mu}_t$ et $\mathbf{H}_t$ soient bien spécifiés) — mais moins efficace que le vrai MLE. Exactement le même principe qu'en univarié (chapitre 3).

Au-delà de la normalité

Comme en univarié, la normalité conditionnelle est rarement réaliste pour des rendements financiers, et le choix de la distribution compte particulièrement pour des applications comme la VaR.

Student multivariée $ST(\mathbf{0}, \mathbf{I}_N, \nu)$:

$$g(\mathbf{z}_t \mid \nu) = \frac{\Gamma\left(\frac{\nu+N}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) [\pi(\nu-2)]^{N/2}} \left[1 + \frac{\mathbf{z}_t' \mathbf{z}_t}{\nu-2}\right]^{-\frac{N+\nu}{2}}$$

$\nu \rightarrow \infty \Rightarrow$ convergence vers $\mathcal{N}(\mathbf{0}, \mathbf{I}_N)$.

Danger symétrique à celui du QMLE gaussien : si la distribution alternative choisie (Student, Student asymétrique, mélange de gaussiennes...) est elle-même mal spécifiée, l'estimateur peut devenir **inconsistant** — contrairement au QMLE gaussien, robuste par construction à une mauvaise spécification de la distribution.

Estimation en deux étapes (CCC/DCC)

En substituant $\mathbf{H}_t = \mathbf{D}_t \mathbf{R}_t \mathbf{D}_t$, la vraisemblance gaussienne se décompose :

$$L_T(\theta) = \underbrace{-\frac{1}{2} \sum_t (2 \log |\mathbf{D}_t| + \mathbf{u}_t' \mathbf{u}_t)}_{Q1L_T(\theta_V)} + \underbrace{-\frac{1}{2} \sum_t (\log |\mathbf{R}_t| + \mathbf{u}_t' \mathbf{R}_t^{-1} \mathbf{u}_t - \mathbf{u}_t' \mathbf{u}_t)}_{Q2L_T(\theta_V, \theta_R)}$$

Étape 1 : $\hat{\theta}_V = \arg \max Q1L_T(\theta_V)$ – s'il n'y a pas d'effet de contagion dans les variances, cela revient simplement à estimer N GARCH **univariés indépendants** (chapitre 3).

Étape 2 : $\hat{\theta}_R = \arg \max Q2L_T(\hat{\theta}_V, \theta_R)$ – beaucoup plus simple qu'une estimation jointe, puisque θ_V est fixé.

Propriétés et coût de l'approche en deux étapes

- Consistants, mais **non efficaces asymptotiquement** (perte d'information sur θ_V à l'étape 1) — Engle (2002), Engle et Sheppard (2001), Aielli (2009).
- La matrice de variance de $\hat{\theta}_R$ doit être corrigée pour tenir compte de l'étape 1 — important pour l'inférence, moins pour la prévision ponctuelle (VaR).

Variance targeting

Idée : remplacer certains paramètres par un estimateur non paramétrique de la variance non conditionnelle, pour réduire le nombre de paramètres à optimiser numériquement. BEKK scalaire :

$$\mathbf{H}_t = (1 - \alpha - \gamma)\hat{\mathbf{H}} + \alpha \boldsymbol{\varepsilon}_{t-1}\boldsymbol{\varepsilon}_{t-1}' + \gamma \mathbf{H}_{t-1}, \quad \hat{\mathbf{H}} = \frac{1}{T} \sum_{t=1}^T \hat{\boldsymbol{\varepsilon}}_t \hat{\boldsymbol{\varepsilon}}_t'$$

Ne laisse plus que **deux** paramètres à optimiser, quel que soit N .

Si N approche T , $\hat{\mathbf{H}}$ devient mal conditionnée (proche de singulière) : Engle, Shepard et Sheppard (2008) montrent par simulation un biais à la baisse marqué de $\hat{\alpha}$, $\hat{\gamma}$ dans ce cas.

Application : VaR de portefeuille et *backtesting*

De $\mathbf{H}_t$ à la VaR d'un portefeuille

Pour un portefeuille de poids $\mathbf{w}$ (constants), le rendement du portefeuille est $r_{p,t} = \mathbf{w}'\mathbf{r}_t$, de moyenne et variance conditionnelles :

$$\mu_{p,t} = \mathbf{w}'\boldsymbol{\mu}_t, \quad \sigma_{p,t}^2 = \mathbf{w}'\mathbf{H}_t\mathbf{w}$$

Sous hypothèse de normalité conditionnelle, la **VaR** du portefeuille au seuil α (ex. 5 %) pour la date $t + 1$:

$$\text{VaR}_{p,t+1}(\alpha) = \mu_{p,t+1} + z_\alpha \sigma_{p,t+1}, \quad z_\alpha = \Phi^{-1}(\alpha)$$

C'est exactement le calcul du TP3 (exercice 6, cas univarié), appliqué ici à $\sigma_{p,t}$ tirée de $\mathbf{H}_t$ plutôt que d'un GARCH seul.

$z_\alpha < 0$ pour $\alpha < 0,5$ (ex. $z_{5\%} = -1,645$) : la VaR est un niveau de rendement, pas une perte positive. Une **violation** à la date t est l'événement $r_{p,t} < \text{VaR}_{p,t}(\alpha)$.

Expected Shortfall (perte moyenne au-delà de la VaR)

Sous normalité, l'**Expected Shortfall** au même seuil :

$$\text{ES}_{p,t+1}(\alpha) = \mu_{p,t+1} - \sigma_{p,t+1} \frac{\phi(z_\alpha)}{\alpha}$$

avec ϕ la densité de la loi normale centrée réduite.

La VaR ne dit rien sur l'**ampleur** d'une perte au-delà du seuil — deux portefeuilles peuvent avoir la même VaR à 5 % et des pertes extrêmes très différentes. L'ES corrige ce défaut ; c'est pourquoi les accords de Bâle (depuis *Basel III/FRTB*) migrent vers l'ES pour le capital réglementaire.

Backtesting : le test de Kupiec (1995)

Sur T jours, on observe $N = \sum_t \mathbb{1}\{r_{p,t} < \text{VaR}_{p,t}(\alpha)\}$ violations, soit un taux $\hat{\pi} = N/T$. Sous H_0 : le modèle est bien calibré ($\pi = \alpha$).

Test du rapport de vraisemblance (*proportion of failures*) :

$$LR_{uc} = -2 \ln \left[\frac{(1 - \alpha)^{T-N} \alpha^N}{(1 - \hat{\pi})^{T-N} \hat{\pi}^N} \right] \underset{H_0}{\sim} \chi^2(1)$$

On rejette H_0 (mauvaise calibration) si LR_{uc} dépasse le quantile $\chi^2_{1,1-c}$ (ex. 3,841 à 95 %).

Q. $T = 250$, $\alpha = 5\%$ (soit 12,5 violations attendues), et on observe $N = 20$ violations. Que conclure ?

R. $\hat{\pi} = 8\%$, $LR_{uc} \approx 4,04 > 3,841$: on **rejette** H_0 à 95 % — le modèle sous-estime le risque (trop de violations, VaR pas assez conservatrice). Calcul détaillé : TD4, exercice 6.

Au-delà de Kupiec : le test de Christoffersen (1998)

Kupiec ne teste que le **nombre** de violations, pas leur **répartition** dans le temps : un modèle peut avoir le bon taux moyen tout en concentrant ses violations pendant les crises (clustering), ce qui est précisément le défaut le plus dangereux en pratique.

Christoffersen ajoute un test d'**indépendance** (LR_{ind} , fondé sur la matrice de transition de l'indicatrice de violation) et combine :

$$LR_{cc} = LR_{uc} + LR_{ind} \underset{H_0}{\sim} \chi^2(2)$$

H_0 : couverture correcte **et** violations indépendantes dans le temps.

Limites et perspectives

Le fléau de la dimension

Au-delà de $N \approx 10$ actifs, seuls les modèles **scalaires** (DCC/BEKK scalaires) ou **factoriels** restent praticables. Des applications à grande échelle existent (Engle et Sheppard, 2001 : DCC scalaire sur 100 séries ; Engle, Shepard et Sheppard, 2008 : jusqu'à 480 séries, avec *targeting*), mais restent l'exception, pas la norme d'un usage courant.

Extensions actuelles : copules-GARCH (GARCH pour les variances + copule dynamique pour la dépendance), mélanges finis de GARCH, modèles à facteurs, utilisation de données haute fréquence (MIDAS, HEAVY).

Logiciels

- R : `rmgarch` (DCC, notamment), `rugarch` (variances univariées en entrée), `mgarchBEKK`, `ccgarch`.
- Matlab (*MFE Toolbox*), OxMetrics (G@RCH), Stata.

Références

- Bauwens, L., Laurent, S., Rombouts, J.V.K. (2006). Multivariate GARCH Models: A Survey. *Journal of Applied Econometrics*, 21, 79-109.
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates: A Multivariate Generalized ARCH Model. *Review of Economics and Statistics*, 72(3), 498-505.
- Bollerslev, T., Engle, R.F., Wooldridge, J.M. (1988). A Capital Asset Pricing Model with Time-Varying Covariances. *Journal of Political Economy*, 96(1), 116-131.
- Engle, R.F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models. *Journal of Business & Economic Statistics*, 20(3), 339-350.
- Engle, R.F., Kroner, K.F. (1995). Multivariate Simultaneous Generalized ARCH. *Econometric Theory*, 11(1), 122-150.
- Silvennoinen, A., Teräsvirta, T. (2009). Multivariate GARCH Models. In *Handbook of Financial Time Series*, Springer, 201-229.